

Stacking et Blending

Advanced Machine Learning - Paire 4

Objectif : comprendre, implémenter et évaluer les ensembles par méta-apprentissage.

Stacking

Blending

OOF

Wine Quality

30 seeds

Objectifs pédagogiques

Ce que le chapitre doit prouver

Présenter le stacking comme méta-apprentissage, maîtriser OOF, différencier blending et relier AML à la régularisation ADL.

[Meta-learning](#)[Anti-leakage](#)[Comparaison](#)[Lien ADL](#)

Plan du cours

De l'intuition à l'expérimentation

Le parcours suit la logique officielle : motivation, architecture, OOF, blending, code, expériences, stabilité et bonnes pratiques.

1. Motivation

2. Stacking

3. OOF

4. Blending

5. Expériences

Pourquoi les ensembles ?

Réduire l'erreur de généralisation

Bagging réduit la variance, boosting réduit le biais, voting combine par règle fixe et stacking apprend une règle de combinaison.

Bagging

Boosting

Voting

Stacking

Limites du vote majoritaire

Le voting est simple mais rigide

Hard voting ignore la confiance ; soft voting dépend de la calibration. Le stacking apprend comment exploiter les modèles.

[Hard voting](#)[Soft voting](#)[Calibration](#)[Poids appris](#)

Stacking : intuition

Apprendre à combiner les modèles

Les prédictions des base learners deviennent des variables d'entrée pour un second modèle : le meta-learner.

Base learners

Meta-features

Meta-learner

$\hat{y} = g(Z)$

Architecture à deux niveaux

Niveau 0 + Niveau 1



LogReg

SVM

RF

XGB

LightGBM

Out-of-Fold

La clé anti-fuite

Chaque ligne de Z_train doit être prédite par un modèle qui n'a jamais vu cette observation.

KFold

OOF

Z_train

No leakage

Data leakage

L'erreur critique du stacking

Si les prédictions in-sample entraînent le meta-learner, le score devient artificiellement optimiste et instable.

In-sample

Overfitting

OOF strict

Pipeline

Contenu mathématique

Formules minimales exigées

$Z[i,j] = h_j^{(-k)}(x_i)$. En probabilités : $Z[i,j,c] = P_j(y=c|x_i)$.
Le meta-learner apprend $g^*(Z)$.

 $Z[i,j]$ $P(y=c|x)$ $g(Z)$

Regularisation

Pseudo-code OOF

Procédure reproductible

Pour chaque modèle et chaque fold : entraîner sur K-1 folds, prédire le fold laissé de côté, stocker dans Z, entraîner g.

train

predict fold

store Z

fit g

Blending

Variante hold-out

Le train set est découpé en D_{base} et D_{blend} . Les base learners apprennent sur D_{base} ; le meta-learner apprend sur D_{blend} .

 D_{base} D_{blend}

Simple

Rapide

Stacking vs Blending

Comparaison centrale

Stacking OOF

KFold, robuste, utilise toutes les données, plus coûteux.

Blending

Hold-out, simple, rapide, dépend du split.

OOF

Hold-out

Robustesse

Coût

Calibration des probabilités

Soft voting et stacking probabiliste

Les probabilités doivent être fiables. Sinon, les modèles mal calibrés peuvent dominer injustement le meta-learner.

[predict_proba](#)[ROC-AUC](#)[Platt](#)[Isotonic](#)

Implémentation maison

CustomStackingClassifier

La classe from scratch montre explicitement la construction OOF, le clonage des modèles et le réentraînement final.

StratifiedKFold

clone

oof_meta_features

fit/predict

Bibliothèques de production

scikit-learn et mlxtend

StackingClassifier et StackingCVClassifier permettent une implémentation fiable et réutilisable dans un pipeline expérimental.

StackingClassifier

StackingCVClassifier

Pipeline

n_jobs

Datasets

Expérience principale + validation secondaire

Wine Quality UCI reste l'expérience principale. Pima Indians Diabetes ou Breast Cancer servent à vérifier la robustesse.

[Wine Quality](#)[Pima](#)[Breast Cancer](#)[Tabular](#)

Protocole expérimental

Comparaison équitable



Split

Pipeline

Baselines

Metrics

Modèles comparés

Best Single vs Voting vs Stacking

LogReg, SVM, KNN, RF, GB, XGB, LGBM, hard/soft voting, custom stacking, sklearn stacking, mlxtend et blending.

Best Single

Voting

Stacking

Blending

Métriques

Performance, robustesse et coût

Accuracy, F1 macro, Precision/Recall macro, ROC-AUC et temps d'entraînement. F1 macro est la métrique centrale.

Accuracy

F1 macro

ROC-AUC

Time

Stabilité sur 30 seeds

Éviter la conclusion chanceuse

Comparer moyenne, écart-type, min, max et boxplots. Un bon modèle doit être performant et stable.

Mean

Std

Boxplot

Robustness

Pont AML × ADL

Stacking et régularisation neuronale

Stacking combine explicitement plusieurs modèles ;
Dropout peut être vu comme un ensemble implicite de sous-réseaux.

Dropout

MC Dropout

BatchNorm

Label smoothing

Pièges et bonnes pratiques

Ce qu'il faut absolument éviter

Fuite de données, modèles trop similaires, meta-learner trop complexe, probabilités mal calibrées et absence de stabilité.

Leakage

Diversity

Calibration

30 seeds

Livrables officiels

Ce que contient le projet

Mini-site HTML, notebooks Colab, code Python, rapport académique, questions professeur, bibliographie, PowerPoint HTML/CSS, PPTX et PDF.

[HTML](#)[Notebooks](#)[PPTX](#)[PDF](#)

Conclusion

Message final à défendre

Le stacking est puissant seulement s'il est construit sans fuite, comparé aux baselines et évalué en stabilité.